

학습은 어디서 통하고 어디서 안 통하는가 (v10)

단계별 원인 귀속, 학습형 infeasibility 판별의 엄밀한 검증, 60×150 에서의 확장성 한계
neuroMCTS 프로젝트 · 2026년 7월

초록

이번 사이클은 새 기법 제안이 아니라 세 가지 구체적 질문에 답한다. 첫째, 학습 요소(GNN 정책이 이끄는 MCTS·DFS 순서)가 심볼릭 단계(전파·LP·영공간 pump·AHL 격자축소) 이후 정확히 얼마나 기여하는가를 인스턴스 단위로 측정했다. 답은 뚜렷하고 단조적이다: 10×25 에서 해 정확도 +7.6~7.75%p, infeasibility 증명 +24.5%p 기여하던 것이 20×50 에서 +0.4%p로 줄고, 40×100 과 60×150 에서는 정확히 0이다. 둘째, 학습이 해 탐색이 아니라 infeasibility 판별이라는, 지금까지 직접 시도되지 않은 과제에서는 통하는지를 완전히 새로운 특징(단발성이 아닌 다회 독립 심볼릭 프로브의 집계 통계)으로 검증했다. 결과는 학습 요소의 여섯 번째 부정 결과이나 지금까지 가장 엄밀하다: 집계 특징 조합은 held-out AUC 0.588(개별 특징은 0.46~0.54)에 도달하지만, 사전학습된 GNN의 그래프 임베딩은 완전히 무신호(AUC 0.497)이며 스칼라 특징과 결합하면 오히려 하락(0.552, 과적합)한다. 최선의 정밀도 지점에서도 깃발 표시된 것의 3분의 1~2분의 1이 실제로는 feasible이어서, FN=0 요구사항 하에서는 쓸 수 없다. 셋째, 학습되거나 이전에 평가된 적 없는 60×150 크기에서 소규모 통계 확인(전수 스윕이 아님)을 수행해 현 AHL 파이프라인의 실질적 확장 한계를 발견했다: 해 정확도가 40×100 의 66.67%에서 60×150 의 6.67%로 붕괴하고 평균 시간은 22.0초에서 108.0초로 증가하며, 이 크기에서도 학습 단계의 기여는 0이다. 이 발견들은 프로젝트의 핵심 결론을 정확하고 반증 가능한 문장으로 버린다: 학습은 최소 크기에서만, 그것도 이미 좁혀진 탐색 잔여집합 안에서의 해 구성·증명에만 기여하며, 어떤 특징으로도 feasibility 판별을 돕지 못하고, 파이프라인의 실질적 성과를 내는 격자 공격 자체도 $n \approx 150$ 부근에서 자체 확장 한계를 갖는다.

1. 질문 1: 학습은 정확히 얼마나 기여하는가

기존 보고서는 학습의 기여를 정성적으로만 서술했다("AHL이 대부분을 풀고, MCTS/DFS가 잔여를 처리한다"). 이번 사이클은 기존 파이프라인의 인스턴스별 결과 기록을 계측해, 해결되거나 증명된 모든 인스턴스를 정확히 어느 단계가 처리했는지 파이프라인 순서대로(전파/probing → LP hard rule → 영공간 pump → AHL 격자축소[전부 심볼릭] → GNN 정책 기반 MCTS 탐색 및 정책 순서 DFS[전부 학습]) 귀속했다.

	10×25	20×50	40×100	60×150
심볼릭만(전파+LP+pump+AHL), feasible 해결	92.25%	77.9%	66.67%	6.67%
+ 학습(MCTS+DFS)	100.0%	78.25%	66.67%	6.67%
학습의 순증분	+7.6~7.75%p	+0.4%p	+0.0%p	+0.0%p
심볼릭, infeasible 증명	72.5%	12.5%	0.0%	10.0%
+ 학습(DFS 증명)	97.0%	12.5%	0.0%	10.0%
학습의 순증분	+24.5%p	+0.0%p	+0.0%p	+0.0%p

표 1. 단계별 해결·증명 원인 귀속. 누적 비율은 각각 전체 feasible/infeasible 대비.




그림 1. (좌) 크기별 단계 누적 해결률 — 학습의 증분(주황/빨강)은 10×25에서만 보이고 40×100 이후로는 0. (우) infeasibility 판별 후보 특징들의 rank-AUC — 점선이 우연(0.5).

패턴은 단조적이고 총체적이다: 학습의 한계 가치는 10×25에서의 유의미함(+7.75, +24.5%p)에서 20×50의 미미함(+0.4%p)을 거쳐 40×100·60×150에서 정확히 0으로 줄어든다. 두 큰 크기에서는 해결되는 모든 인스턴스가 AHL이나 pump로 해결되고, 증명되는 모든 infeasible은 LP hard rule 단독으로 증명된다. MCTS와 DFS는 잔여집합에서 돌지만 아무것도 닫지 못한다.

2. 질문 2: 학습이 infeasibility를 판별할 수 있는가

이 프로젝트에서 다섯 번의 독립적 시도(v5–v7의 정적 특징 GNN 헤드, v6의 pump 실패 통계+focal loss, v9의 시도별 스케줄러)가 feasibility head를 유의미하게 만드는 데 실패했다. 이번 사이클은 완전히 다른 특징군을 검증한다: 단일 심볼릭 프로브의 결과는 무기억이지만(v9 발견), 동일 인스턴스에 대한 다회 독립 프로브의 집계 결과는 다를 수 있다는 가설 — infeasible은 아무리 재시도해도 잔차의 바닥이 안 내려가지만, 어려운-그러나-feasible은 가끔 0에 근접할 것이다.

오프라인 수집기가 전파와 LP hard rule을 통과한(진짜로 모호한) 잔여 인스턴스마다 pump 15회 재시작 + 저비용 AHL 8회 시도를 돌렸다. 20×50에서 4,696건(feasible 3,000/infeasible 1,696), 40×100에서 1,178건을 수집했다. 건전성 확인: 모든 프로브에서 pump·AHL이 인증된 infeasible 인스턴스에 대해 단 한 번도 허위 해를 만들지 않았다(20×50 0/1,696, 40×100 0/578).

특징	AUC
LP 분수도	0.481 (0.519)
pump 잔차, 15회 최소	0.465 (0.535)
pump 잔차, 15회 표준편차	0.464 (0.536)
AHL 최단벡터 노름, 8회 최소	0.513
조합(7특징, 로지스틱)	0.588
조합(7특징, MLP — 선형 대비 이득 없음)	0.588
동결 GNN 풀링 임베딩(512차원) 단독	0.497
임베딩+스칼라 결합	0.552 (스칼라 단독보다 나쁨)

표 2. Held-out rank-AUC(Mann–Whitney), 20×50 잔여집합. 0.5=우연.

개별 특징은 전부 우연 수준(0.46–0.54)이다. 7개 집계 특징의 선형 결합은 0.588로, 개별 최대치보다 진짜 개선(2,500건 독립 부분집합에서 0.595로 재현)이나, 동일 입력의 비선형 MLP는 동일한 점수(0.588)를 내 특징들이 상호작용 없이 가산적으로만 결합됨을 보인다. 가장 시사적인 것은, 동결된 사전학습 GNN의 풀링 그래프 임베딩(파이프라인 전체에서 쓰는 바로 그 체크포인트)이 전혀 신호가 없고(AUC 0.497, 우연과 구분 불가), 7개 스칼라 특징과 결합하면 오히려 0.552로 하락한다는 점이다 — 1,900여 개 학습 예제에 512차원의

무정보 차원을 추가한 과적합 결과다. 이는 feasibility head가 모든 이전 사이클에서 실패한 이유를 직접적·정량적으로 설명한다: 사전학습 트렁크가 만드는 표현(feasible 인스턴스만으로 masked-solution 예측을 통해 학습됨)은 feasible과 infeasible을 애초에 분리하지 못하며, 그 위에 어떤 분류기 용량을 얹어도 없는 것을 복원할 수 없다.

AUC 0.588이 쓸모 있는가? 예측 feasible 확률이 가장 낮은 하위 2%(held-out 약 1,174건 중 22건)를 플래그하는 임계값에서, held-out infeasible 약 433건 중 14건을 포착하나(재현율 3.3%), feasible 8건을 잘못 플래그한다 — 플래그 집합 내 위양성률 36%, 즉 infeasible로 선언될 인스턴스 3개 중 1개 이상이 실제로는 feasible이다. 복구 가능한 스캔을 폐기해서는 안 된다는 프로젝트의 운영 요구사항(FN=0)을 고려하면, 검증한 어떤 임계값에서도 사용 가능한 판별 규칙이 아니다.

이는 학습 요소에 대한 프로젝트의 여섯 번째 독립 부정 결과이나(v6 self-play, v6 순서 REINFORCE, v7 모방, v9 시도 스케줄러에 이어), 가장 엄밀하게 검증된 것이기도 하다: 이론적으로 동기화된 새 특징군(다회 재시작 집계)을 대규모(5,874건)로 수집하고, held-out AUC와 운영점 분석으로 평가했으며, 사전학습된 GNN 표현과 대조해 실패의 이유까지 설명했다. 하드 판별이 아닌 소프트 활용(feasible일 가능성이 높은 인스턴스에 탐색 예산을 더 배분하되 하드 판별은 하지 않는)은 FN=0 요구사항을 위반하지 않는 저위험 대안으로 다음 사이클 후보로 남긴다.

3. 질문 3: 현재 방법의 확장 한계는 어디인가

전수 스윕이 아닌 소규모·저비용 표본으로 확장성을 확인하라는 지시에 따라, 학습되거나 이전에 평가된 적 없는 60×150 크기에서 신규 인스턴스 40개(feasible 30, CP-SAT 인증 infeasible 10)를 생성해 크기별 튜닝된 v9 파이프라인(block 15, AHL 20회 시도)으로 평가했다. block 4개·시도 3회의 예비 탐색이 전부 0% 커버리지를 보이고, block 40이 40×100 에서처럼 폭증할 것으로 판단해 포기한 뒤, 가벼운 재탐색으로 이 설정을 확정했다.

	10×25	20×50	40×100 (N=75)	60×150 (N=40)
실행가능성 정확도(%)	99.4	82.5	80.0	77.5
해 정확도(%)	100.0	78.25	66.67	6.67
평균 시간(초)	0.23	3.78	22.0	108.0

표 3. 60×150 소규모 통계 확인(block 15, AHL 20회 시도) 대 기존 3개 크기.




그림 2. 4개 크기의 해 정확도(좌)와 평균 시간(우). 40×100 과 60×150 사이에서 정확도가 절벽처럼 떨어지는 반면 시간은 꾸준히 증가한다 — 우아한 트레이드오프가 아니라 두 곡선이 불리한 영역으로 함께 진입한다.

해 정확도는 66.67%에서 6.67%로 붕괴하고 시간은 약 5배(22.0→108.0초) 증가한다 — 이는 완만한 anytime 트레이드오프가 아니라 진짜 커버리지 절벽이다. 40×100 에서와 마찬가지로 60×150 에서도 학습

단계의 기여는 0이다(모든 해결은 AHL 또는 LP hard rule). 표본이 작아($N=40$, feasible 30) 해 정확도의 95% 신뢰구간은 넓지만($\pm$ 약 9%p), 급격한 붕괴라는 정성적 결론은 이 불확실성에도 견고하다 — 중심 추정치가 40×100 수치보다 한 자릿수 낮다.

4. 시사점

세 가지 정확하고 반증 가능한 문장이 프로젝트의 핵심 발견을 요약한다. 학습은 최소 크기(10×25)에서 이미 좁혀진 잔여집합 안의 해 구성·infeasibility 증명에만 기여하며, 그 한계 가치는 크기의 단조 감소 함수로서 40×100 에 이르면 정확히 0이 된다. 학습은 파이프라인 자체의 사전학습 표현을 포함해 검증한 어떤 특징으로도 infeasibility를 판별하지 못하며, 여기서 발견한 약한 집계 프로브 신호는 이전 단발성 시도 대비 진짜 개선이지만 $FN=0$ 요구사항 하에서는 아직 쓸 수 없다. 그리고 파이프라인의 실질적 성과를 내는 심볼릭 방법(크기별 튜닝된 AHL 격자축소) 자체도 40×100 과 60×150 사이에 자체 확장 한계를 가지며, 이는 가정이 아니라 직접적인 소규모 측정으로 위치를 확인했다. 이 발견들을 종합하면 현재 기술 수준이 정확히 정의된다: $n \approx 100$ 까지는 강력하고 잘 이해되어 있으며, 그 너머에는 이제 측정된 벽이 있고, 이 문제군에서 학습이 기여할 수 있는 곳과 없는 곳에 대한 확정적·근거 기반 답이 있다.